

FlavorGraph 진행 실험 요약 (ver1 → ver2)

202192020 이연승 · 2026-01-26

핵심(GBDT 기준)

데이터: $N \approx 250$ · $X=231$ · $Y=50$ · style=22

ver1(10×): 평균 $\Delta R^2 < 0$ (best VAE -0.006)

ver2(2×, r=3): best VAE $+0.017 \pm 0.014$

2nd GaussianCopula $+0.008 \pm 0.026$

데이터 & 전처리

데이터

$N \approx 250$

$X=231$ (화학, 연속형)

$Y=50$ (관능, 전문가)

style=22(층화 분할 기준)

전처리/분할

Train/Test=80/20, stratified(style)

log(롱테일) + scaling(스케일)

결측: mean imputation(평균 대체)

포인트

$N_{\text{train}} \approx 175 < D_X = 231 \rightarrow \text{high-D small-N}$

생각해야 할 포인트 $\rightarrow$ 단순 증강은 조합/구조 붕괴 위험

평가 지표

평가 지표

TRTR: train real, test real

기존 데이터로 학습 → 기존 데이터로 테스트 (기준 성능)

AUG: train real + synthetic, test real

(기존+생성)로 학습 → 기존 데이터로 테스트 (증강 효과 확인)

TSTR: train synthetic, test real

생성 데이터로 학습 → 기존 데이터로 테스트 (생성 데이터의 유용성)

KS test : Kolmogorov Smirnov test

기존, 합성의 변수별 분포 모양의 차이 (0에 가까울 수록 분포 동일)

PCD(X-Y) : pairwise correlation difference X-Y

기존 X-Y 간, 합성 X-Y 간 상관관계 차이 (0에 가까울 수록 관계 동일)

DCR : distance to closest record

생성 데이터와 가장 가까운 기존 데이터 간 거리

평가 지표 결과 해석

$\Delta R^2(\text{AUG}-\text{TRTR}) :$

$R^2(\text{AUG}) - R^2(\text{TRTR})$ (양수면 '증강이 도움')

$\Delta \text{RMSE}(\text{AUG}-\text{TRTR}) :$

$\text{RMSE}(\text{AUG}) - \text{RMSE}(\text{TRTR})$ (음수면 '증강이 도움')

실험 설계

사용 모델(6)

Bootstrapping · KDE · Gaussian Copula

VAE · CTGAN · TabDDPM

ver1=10× / ver2=2×(repeats=3)


평가(2축)

구조/분포: KS · PCD(X-Y) · DCR

유용성: ΔR^2 , $\Delta RMSE$ (GBDT/MLP)

프로토콜: TRTR / AUG / TSTR

ver1(x10) 결과 — $\Delta R^2(\text{GBDT})$



수치

TRTR $R^2 \approx 0.178$


$N_{\text{synth}} = 2000$

best: VAE -0.006

2nd: GaussianCopula -0.025

→ 평균 개선 없음


ver2(x2, r=3) 결과



수치

모델


ver2(x2, r=3) 결과



수치

모델

ver2(x2, r=3) 결과



수치

모델

ver2: 상관관계(구조) 분석 — 결과/해석

주요 관찰(해석)

합성 데이터를 '많이' 섞는다고 성능이 좋아지지 않음

합성 품질 점검(PCD, DCR) + 합성 비율(ratio) 최적화가 핵심

Teacher 라벨(예측값) 사용 시 편향이 누적될 수 있음

핵심 수치 예시(GBDT, R^2)

Baseline(Real only) N=200, $R^2 \approx 0.232$

Joint Aug (Full) N=600, $R^2 \approx 0.205$ (↓)

2-Stage (Full) N=600, $R^2 \approx 0.222$ (↓)

2-Stage (Optimal 0.25×) N=250, $R^2 \approx 0.243$ (↑)

다음 액션(추천)

seed 반복 / (가능하면) style 층화 K-fold로 성능 안정성 확인

Real:Syn 비율(ratio sweep)을 기본 루틴으로 고정

상관 보존 강화: copula / feature-group mixup / 상관 제약(loss)

모델 비교: GBDT(XGB/LGBM) + Linear(Ridge/ElasticNet) 병행

다음 실험(키워드)

가설 검증: '데이터 변형 없이'

1) Target Y 선정

GBDT로 50개 관능 성능 스캔 → (test $R^2 \uparrow$, std $\downarrow$) 1~2개 선택

2) 그룹 제거 vs 랜덤 제거

Style 그룹 / 화학 기반 클러스터 → 제거 후 $\Delta R^2(\text{drop})$ vs 랜덤 분포

3) 생성 전략

'구조 보존 + 성능' 동시 만족(조건부 생성 포함) 방향으로 ver3 설계

ver2: 상관관계(구조) 분석 — 설계

목표

원본 데이터의 분포(롱테일/왜도)·의존 구조(상관) 파악
전처리(log/스케일링) 타당성 점검
증강 전에 '구조 보존' 체크리스트(지표) 만들기

분석 파이프라인 / 산출물


정규성·왜도: analysis_1_normality.csv, plot_1_skewness.png
상관 비교: plot_2_correlation_compare.png (Pearson vs Spearman)
유효 차원: plot_3_pca_dimension.png (95% → $D \approx 105$)
구조/군집: plot_4_tsne_structure.png (style별 분리)

핵심 포인트(해석 방향)


선형 상관(Pearson) + 단조 비선형(Spearman)을 같이 보며 구조를 해석
표본이 적을수록 상관 추정 오차 ↑ → shrinkage(수축추정) 고려
style(맥주 스타일)별 분포가 달라서, 분할/검증도 style 층화가 중요

EDA(핵심 그림 4개)


왜도/롱테일



유효 차원(PCA)



상관 구조



구조(t-SNE)

